EX 2

20308003 曾伟超

词汇表

这里使用了一些扩展的正则表达，例如 a-z 表示所有的小写字母，a-zA-Z 表示所有字母

类型	正则表达
十进制数字	`(1-9)(0-9)*`
八进制数字	`0(0-7)*`
标识符	`(a-zA-Z)(a-zA-Z|0-9)*`
关键字(忽略大小写)	`integer | boolean | write | writeln | read`
保留字(忽略大小写)	`if | elsif | then | else | while | begin | do | end | of | var | const | type | procedure | record | array | module`
标点	`, | ;`
算数运算符	`+ | - | \* | div | mod`
关系运算符	`> | >= | < | <= | = | #`
逻辑运算符	`& | or | ~`
赋值运算符	`:=`
选择运算符	`\. | [ | ]`
括号	`( | )`
类型声明	`:`
注释	`\(\*.*?\*\)`

分类依据以及一些说明

关键字和保留字按照了 `ex1` 中的处理办法，将在语法中存在的作为保留字，其它的放入关键字

还有一些是我个人处理中存在些许疑惑的，例如 `div` 是放在算术运算符还是保留字中，`mod` 也是，但是最终考虑到一致性，还是将其放入了算数运算符中，这点对于后面的 `or` 也是相同的道理

而在注释，由于 `*` 和 `()` 本身在正则中有其含义，从而将 `*` 使用 `\` 做转义，`*` 的类似，而为了防止嵌套，需要采取非贪心的策略，即左注释遇到第一个右注释即停止，这里参考了一些扩展正则的标记，使用 `.*?` 来做非贪心的匹配，这样遇到第一个 `*)` 的时候即结束

词法规则

这里为了简化，将所有的运算符都统一使用 Operator 代替

$$Number \rightarrow DEC \mid OCT$$
$$DEC \rightarrow 0(0-9)*$$
$$OCT \rightarrow (1-9)(0-9)*$$
$$Identifier \rightarrow (a-zA-Z)(a-zA-Z|0-9)*$$
$$Marks \rightarrow , | ;$$
$$Operator \rightarrow + | - | * | div | mod | > | >= | < | <= | = | \# | \& | or | \sim | := | \backslash . | [|] | \backslash (| \backslash) | :$$
$$Comment \rightarrow \backslash (\backslash *. *?\backslash * \backslash)$$
$$KeyWords \rightarrow integer | boolean | write | writeln | read$$
$$ReservedWords \rightarrow if | elsif | then | else | while | begin | do | end | of | var | const | type | procedure | record | array | module$$

和高级语言的对比

1. 高级语言如 C/C++，Java 等，其标识符的正则会更加的负责，可以包含如下划线(`_`)存在，而不是仅仅有字母和数字
2. 一些运算符的不同，例如逻辑与在 C/C++ 中是 `&&`，`&` 在 C/C++ 中是按位与，还有 `or` 在 C/C++ 中是 `||`，不等号和相等也都有区别
3. 赋值的区别，赋值在 C/C++ 等高级语言中是 `=`，而在这里是 `:=`，因为这里的 `=` 沿用了数学的相等
4. 注释的不同，这里没有严格的区分单行和多行注释，这里都是用统一的注释，任意被括住的都是被注释部分
5. 类型符号，C/C++ 中没有这个类型符号，靠的是类型前缀声明

JFlex

由于之前曾经使用过 `GNU Flex`，而 `JFlex` 在使用上有很多相似的地方，一些区别可以通过阅读文档很容易的区分，`JFlex` 文件分为三部分，每两个部分之间使用 `%%` 进行分割，从上到下依次为用户代码，一些可选的选项设置，以及最后的词法规则

用户代码部分，主要包含了 `exceptions` 错误类，用于抛出异常

这里由于大小写不敏感，所以需要开启 `ignorecase`，同时手动指定 `class` 为 `OberonScanner`

而对于各个操作符，则是进行了区分，实际上，每一个无论是符号还是保留字还是关键字，都会有独一无二的一个标识符用来区分，具体可以参考 `TokenType.java`，编写完成后进行测试，以 `standalone` 模式进行测试，由于后续的 `JavaCUP` 只是使用返回值，从而可以忽略输出值

```
./gen.sh src/oberon.flex && ./build.sh && ./run.sh ../ex1/testcases/fib.obr
```

得到的结果如下图所示

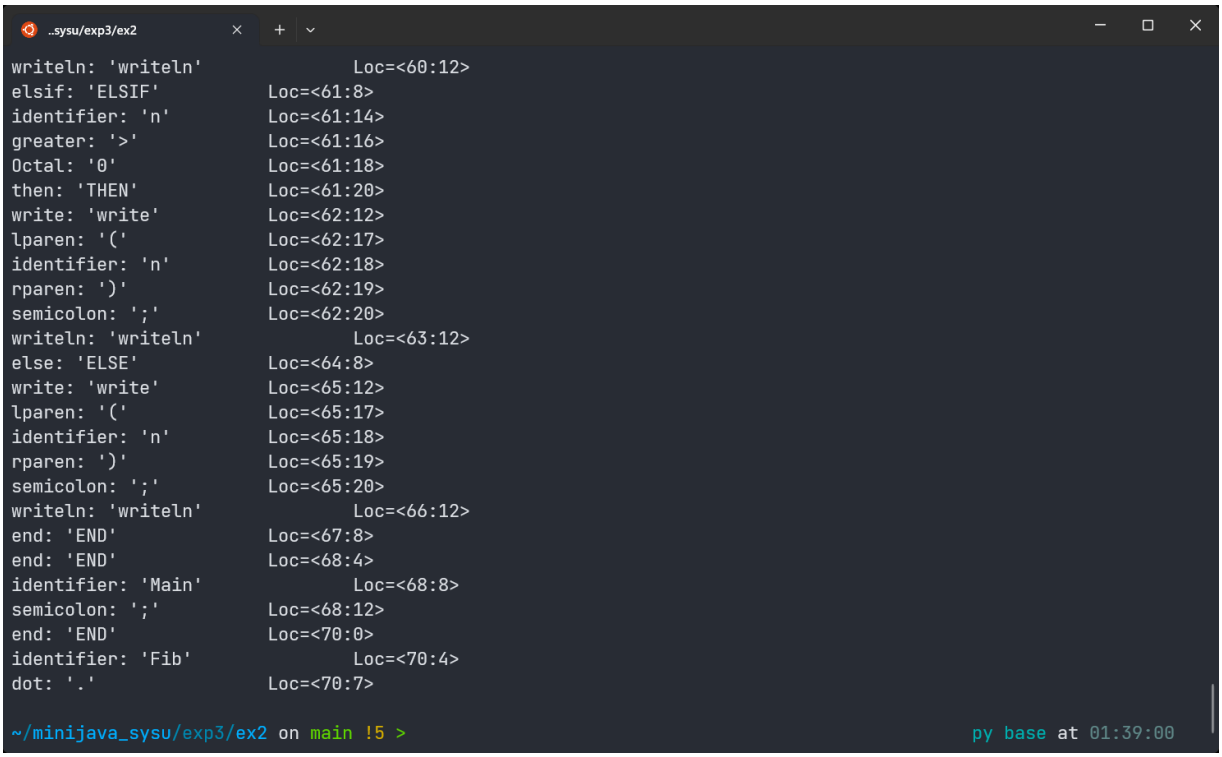

可以看到，能够被成功的进行解析，之后，参考之前的变异，其中设计词法错误的为 001, 002, 012, 013, 014, 015，依次进行测试，如下图

001

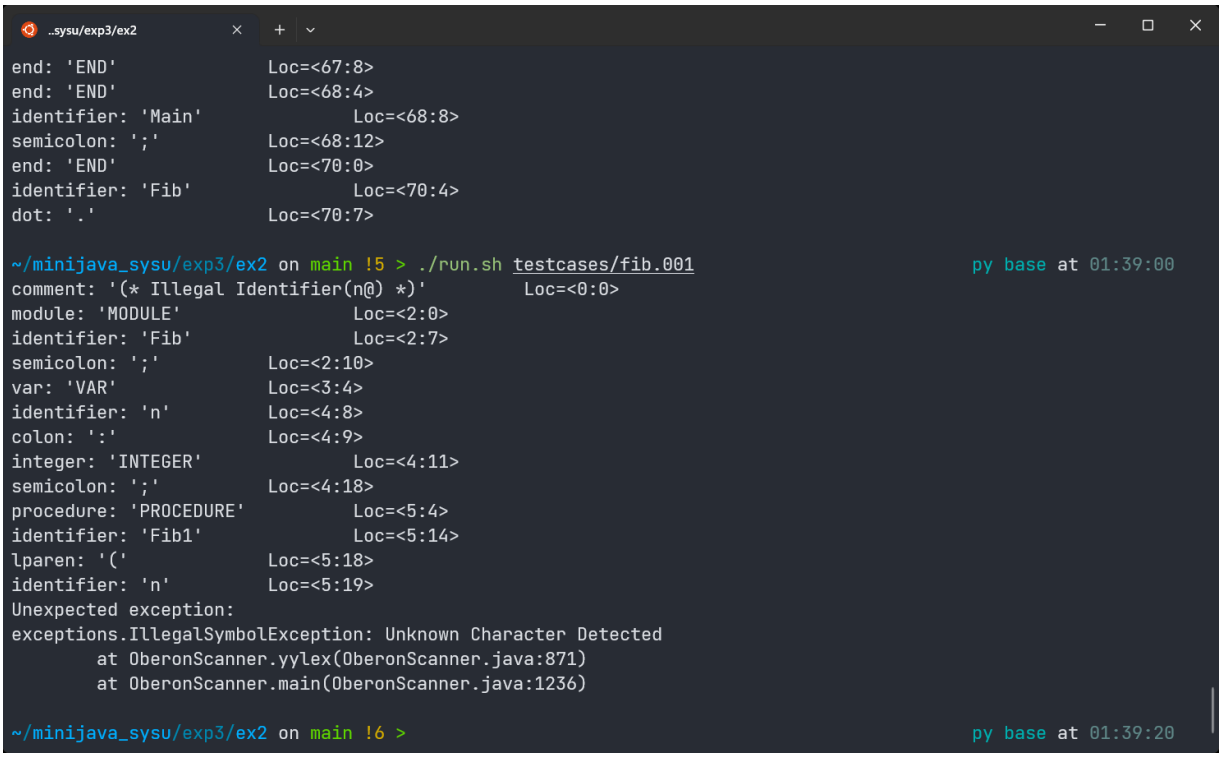

符合报错预期

002

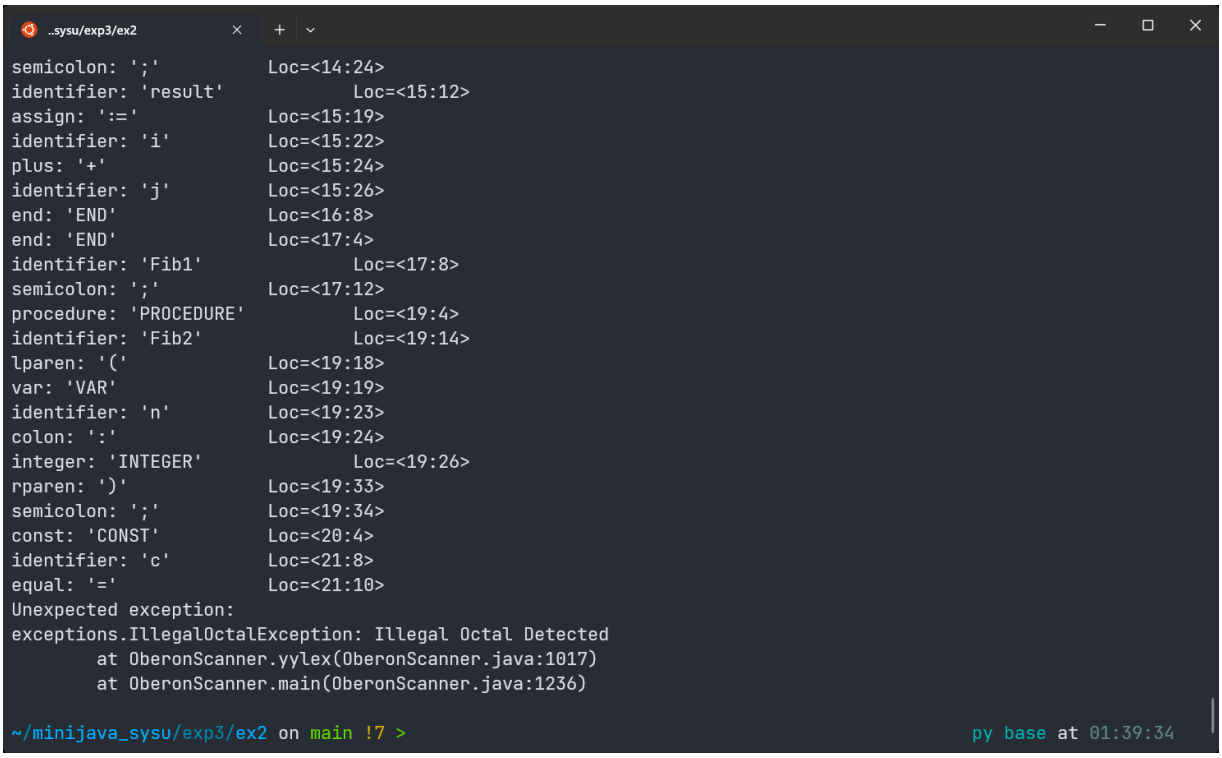

符合报错预期

012

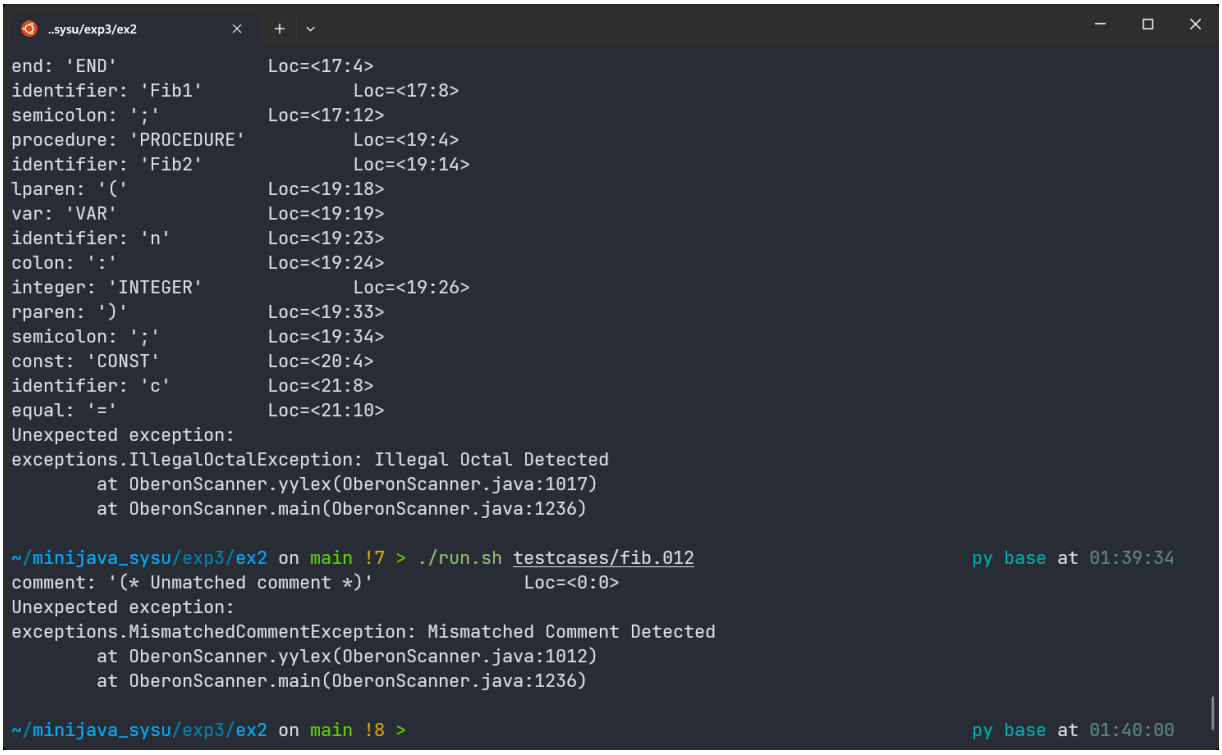

符合报错预期

013

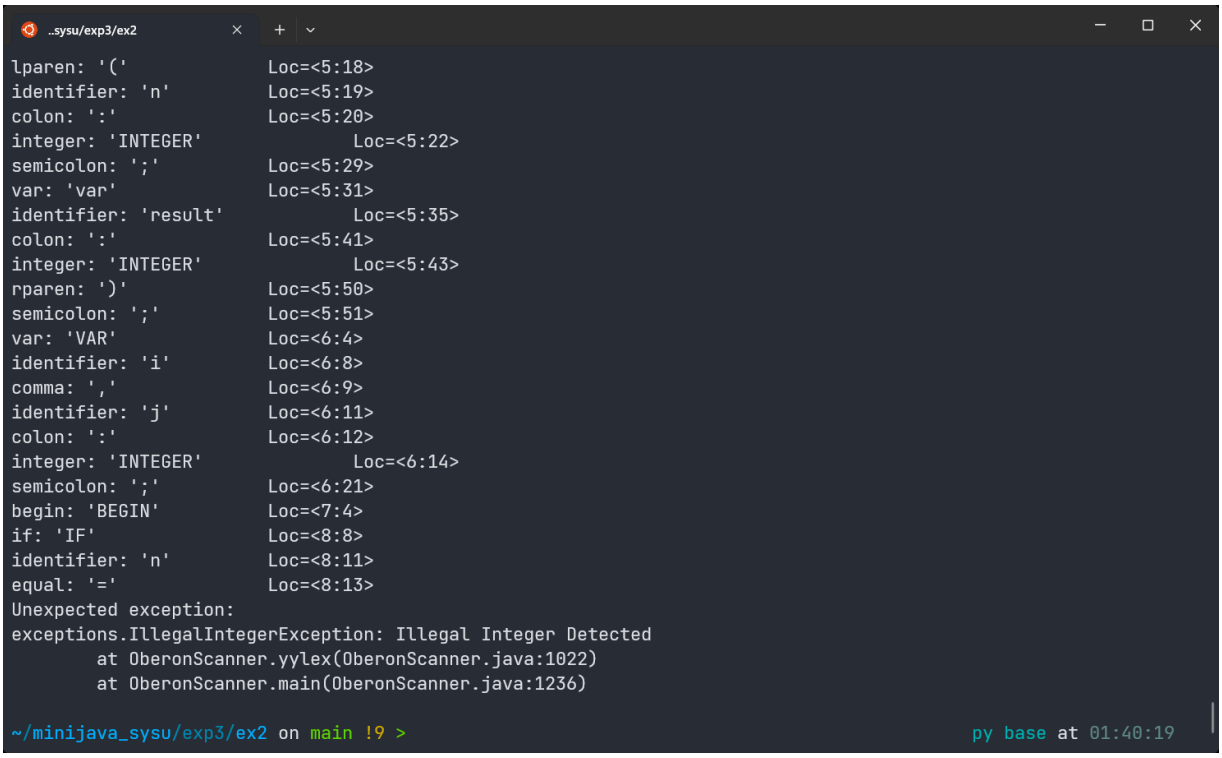

符合报错预期

014

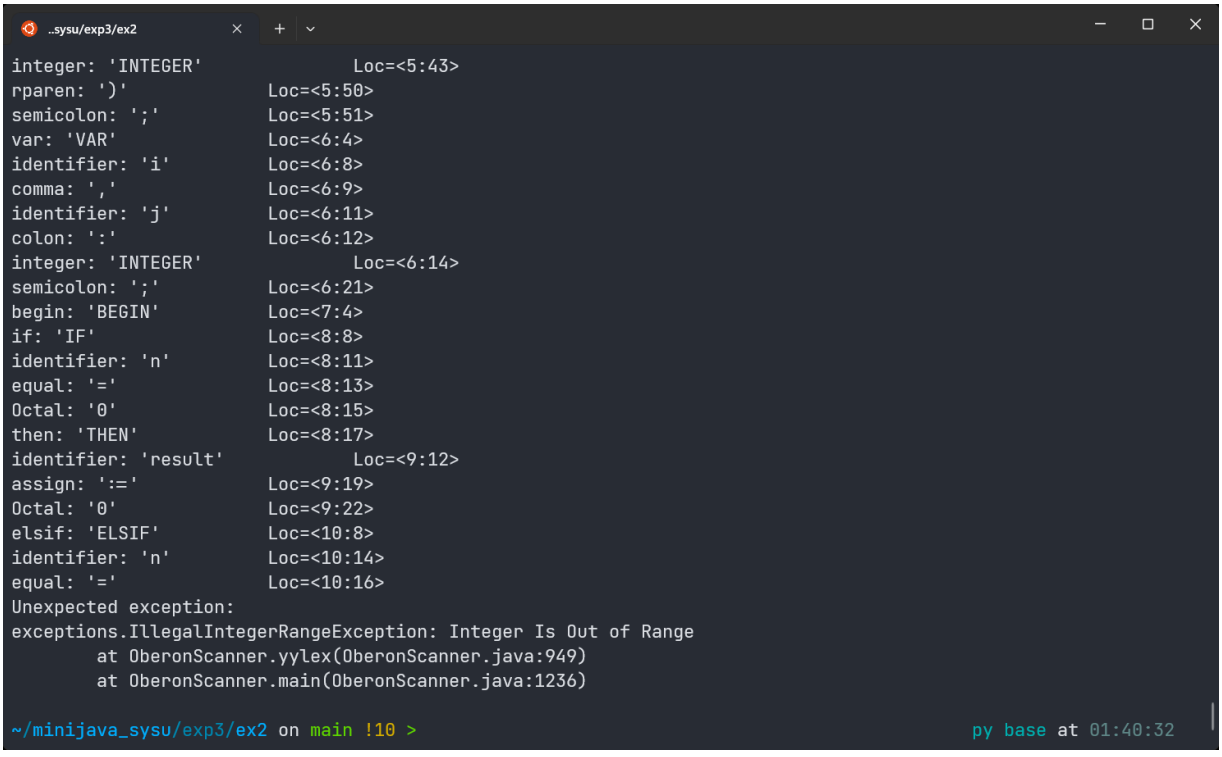

符合报错预期

015

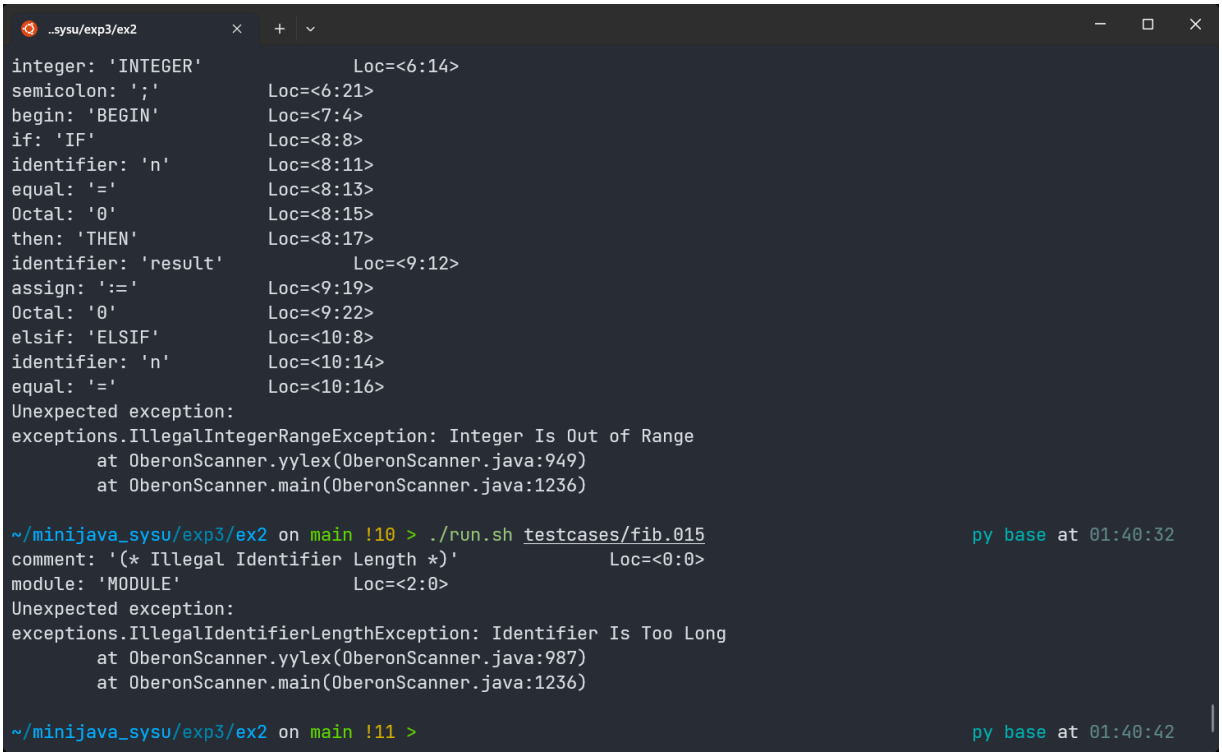

符合报错预期

通过以上的测试，可以基本判断词法分析器的正确性

同时还提供了 `test.sh` 用来对所有 `testcases` 目录下的进行测试，并将对应结果写入到 `results` 文件夹下

对比

之前曾经有使用过 GNU Flex，这里简单说下这两者的异同点，

1. 最明显的，GNU Flex 的目标语言是 C 语言，后续使用 `gcc` 来完成编译，而 JFlex 生成的是 Java 代码，需要使用 `javac` 来完成编译
2. 两者的词法文件都是分割为三个部分，且分隔符都是用的是 `%%`
3. 一些扩展的正则表达式是相同的，例如 `[a-zA-Z]` 在两者都可以使用
4. 配置文件的不同，Flex 的三部分依次为声明(例如一些用户自定义的变量，预处理指令等)，规则(正则表达式)和用户自定义程序(如函数)，而 JFlex 的则是用户程序，选项，规则
5. 由于 GNU Flex 产生的是 C 代码，所以在用户程序中可以直接定义函数入口即 `main` 函数，而 JFlex 则不可以
6. 两者都可以使用 `yytext` 来获取当前匹配的字符串，也都有一些以 `yy` 开头的内置的函数/变量，但在细节上可能有所不同

其它的地方其实都基本相似

而 JLex 和 JFlex 一样，都是生成 Java 代码，且文件分割和 JFlex 相同，个人感觉这两者关系很像是 `flex` 和 `lex`，基本是相同的工具，配置写法也一样，区别主要在于平台上

参考文献

1. 扩展的正则表达式，https://www.runoob.com/regexp/regexp-syntax.html
2. JFlex 文档，https://www.jflex.de/manual.html